

Análisis del 10% de mayores ingresos en Chile

Marcos González, Agustín Rabie

22 January, 2025

Contents

Abstract	1
Objetivos	1
Preparación y descripción de los datos	1
Modelo Entidad-Relación	3
Análisis descriptivo inicial	5
Visualización de la distribución por deciles	7
Caracterización del 10% superior vs resto de la población	8
Análisis territorial	8
Visualización espacial	9
Sexo jefe/a de hogar	10
Edad	11
Nivel educacional	11
Resumen variables potencialmente predictoras	12
Variables potenciales	12
Variables de bienestar de EBS	14
Propuesta de modelo de Machine Learning	15
Modelo	15
Manejo de valores faltantes	15
Partición de datos	16
Entrenamiento del modelo	17
Evaluación del modelo	18
Conclusiones generales:	20
Bibliografía:	20

Abstract

Este estudio analiza los determinantes de la pertenencia al 10% superior de ingresos en Chile utilizando técnicas de machine learning. Mediante el uso combinado de las encuestas CASEN 2020 y EBS 2021, desarrollamos un modelo predictivo que identifica las características socioeconómicas, demográficas y de bienestar subjetivo asociadas a la pertenencia a este grupo. El análisis contribuye a la literatura sobre élites económicas en Chile y América Latina, aportando evidencia sobre los mecanismos de reproducción de la desigualdad económica.

La literatura internacional muestra que el 10% de mayores ingresos presenta características sociodemográficas distintivas que tienen profundas implicaciones para la cohesión social y las políticas públicas: Influencia Política (Gilens, 2012); impacto en Desigualdad y Bienestar (Wilkinson & Pickett, 2010; 2019); Segregación Social (Méndez & Gayo, 2024; Hernando & Mitchell, 2023). En ese contexto, un modelo predictivo de Machine Learning permitirá: - Validar si los patrones internacionales se replican en Chile - Identificar variables no teorizadas previamente

Objetivos

Objetivo General

Desarrollar y evaluar un modelo de machine learning para predecir la pertenencia al 10% superior de ingresos en Chile utilizando datos socioeconómicos y de bienestar.

Objetivos Específicos

- Identificar un conjunto de variables capaces de predecir la pertenencia al 10% superior de ingresos
- Examinar la distribución espacial y las características socioeconómicas del 10% superior de ingresos
- Evaluar el desempeño predictivo de diferentes algoritmos de machine learning
- Analizar la importancia relativa de las variables en la predicción

Preparación y descripción de los datos

Para comenzar el análisis, se cargan las bibliotecas necesarias y se establecen los parámetros de configuración. Se utiliza una combinación de paquetes para manipulación de datos (haven, dplyr, tidyr, purrr, magrittr, stringr), visualización (ggplot2, scales, viridis, DiagrammeR), manejo de datos espaciales (sf, geo-data, chilemapas, rmapshaper) y presentación de resultados (kableExtra), presentación (kableExtra, web-shot2, naniar) y utilidades (devtools, rlang).

`##2.` Carga y preparación inicial de datos El análisis utiliza dos fuentes principales de datos:

CASEN 2020 (versión reducida, en formato rds para poder subirse a GitHub): Proporciona información socioeconómica detallada EBS 2021: Complementa con información adicional (especialmente de bienestar) y factores de expansión actualizados

En el proceso de preparación, se realizan los siguientes pasos: a. Cálculo de deciles de ingreso para identificar el 10% superior según la muestra total de la encuesta CASEN, no de la submuestra de la EBS. b. Creación de variable binaria para el grupo objetivo. c. Merge de ambas bases de datos manteniendo la estructura de la CASEN.

La tabla de resumen del proceso de merge que aparece en el documento muestra que:

- CASEN original tiene 185,437 observaciones: Presenta sólo 98 NAs en la variable `ytotcorh` de ingreso, lo cual es marginal. También debe considerarse que estamos tomando al hogar como unidad y no a individuos (y los individuos que responden la encuesta pueden no corresponder a los/las jefes/as de hogar).

- EBS y la base final fusionada tienen 10,921 observaciones (debe considerarse también que quienes responden no necesariamente con la misma persona que en el caso de CASEN, a pesar de ser el mismo hogar).

Esto implica una retención del 5.9% de la muestra original de CASEN, lo cual es esperable dado que la EBS es una submuestra de CASEN. Lo crucial aquí es verificar que esta submuestra mantiene representatividad, especialmente para el grupo de interés (10% superior).

Representatividad y factores de expansión:

Del análisis de los factores de expansión se observa:

- El 10% superior representa 1,859,535 personas en la población.
- El resto representa 13,304,855 personas.
- La razón de expansión promedio es mayor para el grupo elite (1,909 vs 1,337).

Table 1: Resumen del proceso de merge CASEN-EBS

Etapa	N observaciones	Pérdida de registros	% retención
CASEN original	185437	NA	NA
EBS original	10921	NA	NA
Después del merge	10921	174516	5.9

Table 2: Retención de observaciones por decil después del merge

Decil	N en CASEN	N después del merge	% retención
1	18534	1117	6.0
2	18534	1204	6.5
3	18534	1099	5.9
4	18534	1093	5.9
5	18534	1096	5.9
6	18534	1082	5.8
7	18534	1100	5.9
8	18534	1104	6.0
9	18534	1052	5.7
10	18533	974	5.3
NA	98	NA	NA

Los 974 casos que pertenecen al 10% superior representan aproximadamente el 9% de nuestra muestra, lo cual es consistente con la distribución poblacional esperada. Esto nos proporciona una base sólida para el modelamiento:

- La proporción 9%-91% (vs un 10%-90% ideal) representa un desbalance moderado.
- Es manejable con ponderación de clases en Random Forest.
- No requiere submuestreo de la clase mayoritaria.


Rothman y Greenland (2018) argumentan que es más apropiado planificar el tamaño del estudio basándose en la precisión deseada rather que en el poder estadístico tradicional. En nuestro caso, con 974 casos de 10,921 observaciones, alcanzamos una precisión adecuada.

En términos del tamaño muestral requerido para el análisis predictivo, considerando aproximadamente 45 predictores candidatos (6-1[dummy] en bienestar, 9-1 en tenencia, 5-1 en nivel educacional, 12-1 intervalos de edad, 16-1 en Región, más zona y sexo), los 974 eventos nos proporcionan 21.6 eventos por variable, superando los umbrales mínimos estándar en la literatura de predicción. Si bien este criterio es simplificador (van Smeden et al., 2019), proporciona una base razonable para proceder con el análisis predictivo propuesto.

Modelo Entidad-Relación

El diagrama presentado muestra la estructura de los datos, que se organiza en cuatro entidades principales:

- REGIÓN {id_region}: Permite el análisis territorial de la distribución del ingreso.
- HOGAR {folio_casen} Unidad fundamental de análisis económico.
- INDIVIDUO {id_persona_casen} Unidad básica de observación.
- CARACTERÍSTICAS: Atributos del individuo (sea o no jefe/a de hogar).



Análisis descriptivo inicial

Examinación de valores faltantes El gráfico de patrones de valores faltantes nos muestra una estructura importante:

- Variables sin datos faltantes (0% missing): Variables sociodemográficas básicas (edad, sexo, zona, región) Variables económicas (ytotcorh, elite, fexp) Variables educativas (e6a) Variables de vivienda (v13)
- Variables con alta tasa de missing (~42%): Variables de bienestar laboral (j3a_1, j3a_4, j3a_5): 4,606 casos missing Variables de uso del tiempo (a3_4, c3_2, c6): 4,606 casos missing
- Variables con tasa media de missing (~35%): Tenencia de vivienda (v13_propia): 3,805 casos missing

Esto sugiere: Las variables socioeconómicas básicas están completas. Hay un patrón sistemático de no respuesta en variables de bienestar. La pérdida de información en variables de bienestar afecta aproximadamente al 42% de la muestra.




Table 3: Resumen detallado de valores faltantes por variable


Variable	N Missing	% Missing	Total Obs	Obs Disponibles
j3a_1	4606	42.18	10921	6315
j3a_4	4606	42.18	10921	6315

a3_4	4606	42.18	10921	6315
j3a_5	4606	42.18	10921	6315
c3_2	4606	42.18	10921	6315
c6	4606	42.18	10921	6315
v13_propia	3805	34.84	10921	7116
edad	0	0.00	10921	10921
sexo	0	0.00	10921	10921
zona	0	0.00	10921	10921
region	0	0.00	10921	10921
e6a	0	0.00	10921	10921
v13	0	0.00	10921	10921
ytotcorh	0	0.00	10921	10921
elite	0	0.00	10921	10921
fexp	0	0.00	10921	10921
c1_4	0	0.00	10921	10921
c1_5	0	0.00	10921	10921

Visualización de la distribución por deciles

El gráfico de ingresos promedio por decil muestra una marcada desigualdad. El décimo decil (en rojo) tiene un ingreso promedio de más de 4 millones de pesos. La diferencia con el noveno decil es especialmente notoria, pues el 10% superior captura 40.5% del ingreso total.

```
## pdf
## 2
```



Caracterización del 10% superior vs resto de la población

La tabla siguiente compara características clave entre este grupo y el resto de la población. Se incluyen variables territoriales (región, urbano/rural), demográficas (edad, sexo), socioeconómicas (educación) y de bienestar. Los valores están ponderados usando los factores de expansión provistos por la EBS: seleccionamos éstos en vez de los de CASEN por tratarse de una encuesta bifásica.

\begin{table} \caption{Características del 10% superior vs resto}

elite_label	n	n_expandido	ingreso_promedio	desv_est	edad_promedio	prop_hombres	prop_urbano
10% superior	974	1,859,535	4,460,648	2,993,049	41.27	0.56	0.95
Resto	9,947	13,304,855	917,774	500,956	44.87	0.48	0.87


\end{table}


Análisis territorial

El análisis territorial se desarrolla en dos dimensiones complementarias:

Proporción interna: Qué porcentaje de la población de cada región pertenece al 10% superior
Distribución nacional: Cómo se distribuye el total del 10% superior entre las regiones

Para facilitar la interpretación, se ordenan las regiones de norte a sur.





Los gráficos resultantes revelan patrones interesantes. La proporción de elite dentro de cada región (gráfico azul) muestra una concentración en ciertas regiones (Magallanes, RM, Antofagasta,) La distribución del total de la elite (gráfico rojo) evidencia una fuerte centralización en RM.

Visualización espacial


Aquí generamos mapas que permiten una visualización más intuitiva de los patrones espaciales. Se utilizan dos mapas que corresponden a las mismas dimensiones analizadas en los gráficos de barras:

El primer mapa muestra la proporción de habitantes de cada región que pertenece al 10% superior. Este mapa ayuda a identificar dónde es más probable encontrar miembros de la elite económica. El segundo mapa (en tonos magma) visualiza cómo se distribuye el total de ese 10% entre las regiones.

Para la construcción de estos mapas, se enfrentaron varios desafíos técnicos: La necesidad de compatibilizar diferentes codificaciones de regiones: Magallanes tenía problemas de visualización que lo convertía persistentemente en NA.

Proporción del 10% superior por región


% de habitantes de cada región que pertenece al 10% superior



Fuente: CASEN 2020

Distribución regional del 10% superior

Cómo se distribuye el 10% superior entre las regiones



Fuente: CASEN 2020

Sexo jefe/a de hogar

Recodificación para identificar sexo de jefe de hogar. No es posible saberlo para el 100% de los casos, pero con variables de sexo y de relación de quien responde con jefe/a de hogar, se puede reducir para cerca del 70%.

Table 4: Distribución de parentesco

Parentesco	Frecuencia
Jefe(a) de Hogar	5164
Esposo(a) o pareja de distinto sexo	2442
Esposo(a) o pareja de igual sexo	18
Hijo(a) de ambos	1078
Hijo(a) sólo del jefe(a)	1331
Hijo(a) sólo del esposo(a)/pareja	65
Padre o madre	123
Suegro(a)	34
Yerno o nuera	119
Nieto(a)	234
Hermano(a)	138
Cuñado(a)	20
Otro Familiar	98
No familiar	57

Table 5: Distribución y proporción de elite por sexo del jefe de hogar

Sexo	N	N expandido	Proporción elite	Proporción muestra	Proporción población
Mujer	2710	3129383	6.2%	0.525	0.454
Hombre	2454	3757075	14.1%	0.475	0.546

[1] "\nDistribución del sexo del jefe de hogar (incluyendo inferidos):"

##

1 2 <NA>

4357 3267 3297

Observaciones importantes: - Los hogares con jefatura masculina tienen más del doble de probabilidad de pertenecer al 10% superior. - Hay una discrepancia entre proporción muestral y poblacional que sugiere sobremuestreo de - hogares con jefatura femenina. - La proporción de elite es notablemente menor en hogares con jefatura femenina.

Edad

Se utilizan intervalos quinquenales desde los 30 años e intervalos más amplios en edades extremas. Concentración en edades medias: El peak de proporción elite está en 30-34 años (19.5%) y 35-39 años (17.3%). Declina consistentemente después de los 40.

Tiene muy baja representación en extremos: jóvenes (2.2% en 18-29) y casi nula en mayores de 80 (0.3%). Declina fuertemente después de los 70 años.

Diferencias muestra-población: - Ligera subrepresentación de grupos 30-39 años. - Sobrerrepresentación de grupos mayores. - Factor de expansión utilizados.

Nivel educacional

Decisiones clave aquí: - Agrupación en 5 categorías principales - Distinción entre educación técnica y universitaria - Postgrado como categoría separada, a pesar del bajo N, por la sobrerrepresentación del 10% superior. - Manejo explícito de valores NA

Table 6: Distribución y proporción de elite por grupo de edad

Grupo de edad	N	N expandido	Proporción elite (ponderada)	Proporción muestra	Proporción población
18-29	293	435288	2.2%	0.057	0.063
30-34	397	670537	19.5%	0.077	0.097
35-39	433	694170	17.3%	0.084	0.101
40-44	486	770243	13.2%	0.094	0.112
45-49	564	674818	14.3%	0.109	0.098
50-54	584	717096	9.3%	0.113	0.104
55-59	593	782963	8.9%	0.115	0.114
60-64	563	625209	8.7%	0.109	0.091
65-69	466	552611	6.5%	0.090	0.080
70-74	361	436181	5.5%	0.070	0.063
75-79	248	282900	5.4%	0.048	0.041
80 o más	176	244442	0.3%	0.034	0.035

Table 7: Distribución y proporción de elite por nivel educacional

Nivel educacional	N	N expandido	Proporción elite (ponderada)	Proporción muestra	Proporción población
Hasta básica	2453	2879582	1.3%	0.225	0.190
Hasta media	4613	6227468	4.3%	0.422	0.411
Postgrado	188	334451	58.7%	0.017	0.022
Técnica superior	1302	1879090	9.9%	0.119	0.124
Universitaria	2365	3843799	30.5%	0.217	0.253

Gradiente educacional marcado: - Postgrado: 58.7% pertenece al 10% superior; Universitaria: 30.5%;
Técnica superior: 9.9%; Media o menos: < 5%.

Marcada diferencia con distribución poblacional: 41.1% tiene hasta educación media; 25.3% tiene educación universitaria; Solo 2.2% tiene postgrado.

Resumen variables potencialmente predictoras

Para preparar la fase de modelamiento, se realiza un análisis exploratorio de las variables que podrían predecir la pertenencia al 10% superior. El análisis de estas variables se realiza considerando: - Su distribución diferenciada entre elite y no elite - La presencia de valores faltantes que podrían afectar el modelamiento - La necesidad de transformaciones o recodificaciones para su uso en modelos predictivos

Decisiones relevantes: - Combinación de tipo (v13) y propiedad (v13_propia) - Distinción entre vivienda pagada y en proceso de pago - Categorización explícita de situaciones irregulares

Patrones destacados: Alta proporción elite en vivienda propia pagándose (36.1%), mucho más que en vivienda propia pagada (9.7%). Respecto a la muestra total, hay un predominio de vivienda propia pagada (55.1%) e importante sector de arriendo (19.2%).

Casos especiales: Alto porcentaje elite en propiedad compartida pagándose (88.4%), pero muy pocos casos (n=3).

Variables potenciales

La tabla resultante proporciona una primera aproximación a la capacidad predictiva de cada variable, mostrando diferencias significativas en varias dimensiones entre el grupo elite y el resto de la población.

Table 8: Distribución y proporción de elite por tenencia de vivienda

Tenencia	N	N expandido	Proporción elite (ponderada)	Proporción muestra	Proporción
Propia pagada	6022	7424366	9.7%	0.551	
Propia pagándose	1052	2100421	36.1%	0.096	
Propia compartida (pagada)	39	65280	12.9%	0.004	
Propia compartida (pagándose)	3	6793	88.4%	0.000	
Arrendada	2097	3307550	8.4%	0.192	
Cedida	1305	1707647	3.9%	0.119	
Usufructo	301	406743	5.1%	0.028	
Ocupación irregular	74	111732	0.2%	0.007	
Poseedor irregular	28	33858	0.0%	0.003	

Table 9: Estadísticas de edad por grupo

elite_label	N	Media	DE	NA's (%)
10% superior	974	41.27	16.05	0%
Resto	9947	44.87	17.84	0%

Table 10: Distribución por sexo

sexo	N sin ponderar	N ponderado	N elite	% del total	% Elite (ponderado)	NA's (%)
Mujer	6308	7753344	477	57.8%	10.6%	0%
Hombre	4613	7411046	497	42.2%	14.0%	0%

Table 11: Distribución por zona

zona	N sin ponderar	N ponderado	N elite	% del total	% Elite (ponderado)	NA's (%)
Urbana	9307	13405487	916	85.2%	13.2%	0%
Rural	1614	1758903	58	14.8%	5.3%	0%

Table 12: Distribución por región

region_nombre	N sin ponderar	N ponderado	N elite	% del total	% Elite (ponderado)	NA's (%)
Metropolitana	1138	6412096	205	10.4%	18.9%	0%
Valparaíso	851	1541851	66	7.8%	7.7%	0%
Biobío	761	1289286	39	7.0%	5.9%	0%
Araucanía	664	776319	31	6.1%	5.1%	0%
Ñuble	645	399028	23	5.9%	3.4%	0%
O'Higgins	644	766289	40	5.9%	7.8%	0%
Los Lagos	633	687519	48	5.8%	7.7%	0%
Los Ríos	631	315343	34	5.8%	6.0%	0%
Coquimbo	623	641782	33	5.7%	6.5%	0%
Antofagasta	623	527209	85	5.7%	14.8%	0%
Tarapacá	623	285450	68	5.7%	11.6%	0%
Atacama	621	233615	57	5.7%	9.9%	0%
Maule	620	876150	26	5.7%	4.6%	0%
Aysén	618	80017	67	5.7%	10.1%	0%
Arica y Parinacota	617	191704	47	5.6%	7.6%	0%
Magallanes	609	140732	105	5.6%	20.4%	0%

Table 13: Distribución por nivel educacional

educ_rec	N sin ponderar	N ponderado	N elite	% del total	% Elite (ponderado)	NA's (%)
Hasta media	4613	6227468	184	42.2%	4.3%	0%
Hasta básica	2453	2879582	34	22.5%	1.3%	0%
Universitaria	2365	3843799	535	21.7%	30.5%	0%
Técnica superior	1302	1879090	125	11.9%	9.9%	0%
Postgrado	188	334451	96	1.7%	58.7%	0%

Table 14: Distribución por tenencia de vivienda

tenencia_vivienda	N sin ponderar	N ponderado	N elite	% del total	% Elite (ponderado)	NA's (%)
Propia pagada	6022	7424366	446	55.1%	9.7%	0%
Arrendada	2097	3307550	131	19.2%	8.4%	0%
Cedida	1305	1707647	51	11.9%	3.9%	0%
Propia pagándose	1052	2100421	329	9.6%	36.1%	0%
Usufructo	301	406743	13	2.8%	5.1%	0%
Ocupación irregular	74	111732	1	0.7%	0.2%	0%
Propia compartida (pagada)	39	65280	2	0.4%	12.9%	0%
Poseedor irregular	28	33858	0	0.3%	0.0%	0%
Propia compartida (pagándose)	3	6793	1	0.0%	88.4%	0%

Por ejemplo, el 10% es más joven en promedio (41,27 vs 44,87) y tiene mayor proporción de hombres (14% vs 10,6%) y hay fuerte concentración en urbes (13,2% vs 5,3%).

Sin embargo, hay importantes diferencias en la calidad de los datos. Las variables básicas tienen pocos valores faltantes (0% NA's) y hay buena representatividad en categorías principales.

Variables de bienestar de EBS

Decisiones importantes aquí: - Uso de scale() para normalizar variables - Restricción a valores 1-5 en la escala original - Codificación explícita de NA para otros valores

Patrones clave identificados - Diferencias positivas para el 10% superior: Mayor logro de metas, mayor apoyo empleabilidad; mejor balance trabajo-vida. - Diferencias negativas/neutras: Menor interferencia doméstica; Diferencias mínimas en satisfacción con tiempo y flexibilidad de ausencias.

Implicancias para el análisis: - Las variables de bienestar muestran diferencias sistemáticas. - Potencial predictivo moderado pero consistente. - Sin embargo, alto número de NAs. - Se podría considerar un índice compuesto de bienestar.

Table 15: Comparación de variables de bienestar entre grupos (valores estandarizados)

Variable	Media no elite	DE no elite	Media elite	DE elite
Apoyo a empleabilidad	-0.03	1.00	0.20	0.95
Balance trabajo-vida	-0.02	1.00	0.14	0.96
Satisfacción con tiempo	-0.01	1.00	0.05	1.02
Logro de metas	-0.05	1.01	0.40	0.84
Interferencia doméstica	0.01	1.01	-0.09	0.95
Flexibilidad ausencias	0.78	0.42	0.83	0.38

Propuesta de modelo de Machine Learning

A partir de lo anterior, se sugiere un Random Forest para predecir la pertenencia al 10% superior de ingresos. Esta elección se fundamenta en varias características específicas de nuestros datos y objetivos analíticos. En primer lugar, hemos identificado relaciones no lineales importantes, particularmente en variables como edad y educación. Random Forest, al construir múltiples árboles de decisión, puede capturar estas no linealidades sin necesidad de especificación explícita.

Además, nuestros datos presentan una estructura jerárquica territorial, con importantes efectos de interacción entre variables socioeconómicas y ubicación geográfica. Por ejemplo, el significado de un determinado nivel de ingreso en variables de bienestar podría variar según la región (Mac-Clure et al., 2014). Random Forest maneja naturalmente estas interacciones a través de su proceso de construcción de árboles y la selección aleatoria de variables en cada división.

El desbalance moderado en nuestra variable objetivo (9% vs 91%) también se alinea con las fortalezas de Random Forest, especialmente cuando se implementa con pesos de clase ajustados. Esto es particularmente relevante dado que nuestro interés principal es identificar correctamente a los miembros de un grupo minoritario.

Para la implementación específica, proponemos utilizar la librería ranger en R, que permite un manejo eficiente de datos de gran escala y ofrece opciones para importancia de variables permutacional. Sugerimos una configuración inicial con 1000 árboles, mtry igual a la raíz cuadrada del número de predictores, y un tamaño mínimo de nodo de 5 observaciones. La validación cruzada se realizará mediante una estratificación espacial por región para mantener la representatividad geográfica.

Las variables de bienestar subjetivo, que presentan patrones significativos de valores faltantes (42%), serán manejadas mediante imputación múltiple antes del modelamiento, creando cinco conjuntos de datos completos. También estamos considerando construir un índice de bienestar.

Modelo

Codificación de variables categóricas: Se mantienen las categorías originales pero se asignan etiquetas semánticamente significativas. La recodificación preserva el orden natural de las categorías (especialmente importante en educación). Se estandariza el formato usando factores, lo que es crucial para Random Forest

Educación: Se agrupa en 5 niveles. El postgrado se mantiene como categoría separada debido a su alta asociación con la variable objetivo.

Vivienda: Se combina la información de tipo (v13) y propiedad (v13_propia) para crear categorías mutuamente excluyentes. Se mantiene la distinción entre viviendas pagadas y pagándose, dado que vimos diferencias significativas en el análisis descriptivo. Se preservan las categorías de tenencia irregular a pesar de su bajo N, pues su ausencia en el 10% superior es informativa.

Variables de bienestar: Se aplica estandarización (scale) para facilitar la comparabilidad entre variables. Se restringe el rango válido a 1-5 para filtrar valores atípicos (tratados como NAs). La estandarización se aplica antes de la imputación para mantener la distribución original.

Variables adicionales de bienestar: Se mantiene la coherencia en la estandarización para satisfacción_tiempo, logro_metas e interferencia_domestica. flexibilidad_ausencias se trata diferente por ser binaria.

Manejo de valores faltantes

Control de calidad: Se usa case_when para manejo explícito de valores no válidos. Se extrae [,1] del resultado de scale() para mantener solo los valores estandarizados sin atributos. Se mantiene la estructura numérica para las variables de bienestar, permitiendo capturar relaciones no lineales.

Creación de indicador de missing: Se crea un indicador binario para capturar el patrón de no respuesta. Esta decisión es crucial dado el alto porcentaje (~42%) de valores faltantes en variables de bienestar. El indicador permite al modelo aprender de los patrones de no respuesta.

Variable objetivo: Se recodifica como factor con etiquetas explícitas (“No”/“Si”). Se mantiene el orden natural (0/1) en los levels para facilitar la interpretación de probabilidades. Esta codificación es compatible con la implementación de Random Forest en ranger.

Partición de datos

Estratificación: Se usa createDataPartition para mantener la proporción de la variable objetivo (9% elite). La proporción 70-30 equilibra tamaño de entrenamiento y validación confiable.

Los resultados muestran que se mantuvo la proporción: Muestra original: 10,921 casos Total en entrenamiento + prueba: $7,645 + 3,276 = 10,921$. Entrenamiento: 8.9% elite (682/7,645) Prueba: 8.9% elite (292/3,276)

Configuración del modelo: Se utiliza una estrategia de validación que divide los datos en tres partes para asegurar que el modelo aprende bien sin tomar demasiado tiempo en procesar (iteraciones anteriores duraron más de media hora). Como hay muchos más casos fuera del 10% superior que dentro, se ajustan los pesos para que el modelo preste igual atención a ambos grupos. Además, se configura el modelo para que nos dé no solo predicciones simples (sí/no) sino también la probabilidad de pertenecer al grupo elite, lo que nos permite evaluar qué tan seguro está de sus predicciones.

Se prueba el modelo con diferentes configuraciones: primero, dejándolo considerar 3 o 5 variables cada vez que toma una decisión (esto ayuda a que no se concentre demasiado en unas pocas características).

También se prueba qué tan pequeños pueden ser los grupos que forma (3 o 10 casos como mínimo) para encontrar un balance entre aprender patrones detallados y no sobre-ajustarse a casos particulares. Para tomar estas decisiones, se usa un método (llamado gini) que funciona bien cuando un grupo es mucho más pequeño que el otro, como es nuestro caso con el 10% superior.

Los resultados muestran que se mantiene la distribución regional en ambos conjuntos, crucial dado el componente territorial del análisis.

Table 16: Distribución de clases en conjuntos de entrenamiento y prueba

Conjunto	Clase	Frecuencia	Proporción
Entrenamiento	No	6963	0.911
Entrenamiento	Si	682	0.089
Prueba	No	2984	0.911
Prueba	Si	292	0.089

Table 17: Distribución por región en conjuntos de entrenamiento y prueba

Region	Entrenamiento.Var1	Entrenamiento.Freq	Prueba.Var1	Prueba.Freq
1	1	444	1	179
2	10	436	10	197
3	11	423	11	195
4	12	447	12	162
5	13	778	13	360
6	14	445	14	186

7	15	456	15	161
8	16	447	16	198
9	2	438	2	185
10	3	424	3	197
11	4	427	4	196
12	5	606	5	245
13	6	448	6	196
14	7	436	7	184
15	8	536	8	225
16	9	454	9	210

Entrenamiento del modelo

El modelo de Random Forest se entrenó para identificar a quienes pertenecen al 10% superior de ingresos usando una combinación de características socioeconómicas, territoriales y de bienestar. Los resultados son notablemente buenos, pero con algunos matices importantes:

Precisión General: El modelo acierta en el 94% de los casos (Accuracy = 0.940). El área bajo la curva ROC de 0.939 indica una excelente capacidad discriminativa. Estos números sugieren que la pertenencia al 10% superior es altamente predecible a partir de las variables seleccionadas.

Detección de Elite: El modelo identifica correctamente al 97.6% de quienes realmente pertenecen al 10% superior. Este alto porcentaje sugiere que la elite económica tiene características distintivas muy marcadas. La baja tasa de falsos negativos (2.4%) indica que es raro que el modelo “se pierda” a alguien del 10% superior

Falsos Positivos: La especificidad de 57.9% indica que el modelo tiende a sobreidentificar potenciales miembros de la elite. Aproximadamente el 42% de personas clasificadas como del 10% superior por el modelo no lo son. Esto sugiere la existencia de un grupo significativo que comparte características pero no alcanza el umbral de ingresos.

Implicancias y limitaciones: La alta predictibilidad sugiere barreras significativas entre grupos socioeconómicos. Los falsos positivos podrían representar un grupo con educación similar a la elite pero menor ingreso. La precisión territorial del modelo confirma la importancia de la segregación espacial. El modelo es mejor identificando quién sí pertenece a la elite que quién no. La tendencia a falsos positivos sugiere que las características asociadas a la elite no garantizan la pertenencia a ella.

Estos resultados tienen implicaciones importantes para entender la reproducción de la desigualdad en Chile. La alta capacidad predictiva del modelo sugiere que la pertenencia al 10% superior está fuertemente estructurada por una combinación de factores sociales, educativos y territoriales. El patrón de errores del modelo también es informativo: es más propenso a “sobreidentificar” que a “subidentificar”.

Table 18: Resultados del modelo por configuración de hiperparámetros

mtry	min.node.size	splitrule	ROC	Sens	Spec	ROCSD	SensSD	SpecSD
3	3	gini	0.921	0.973	0.463	0.005	0.005	0.040
3	10	gini	0.921	0.971	0.484	0.005	0.005	0.038
5	3	gini	0.917	0.974	0.462	0.003	0.006	0.036
5	10	gini	0.918	0.971	0.466	0.004	0.005	0.046

Evaluación del modelo

El nivel educacional emerge como el predictor más potente, particularmente la distinción entre educación universitaria/postgrado y el resto. La región de residencia es el segundo factor más importante, reflejando la marcada concentración territorial de la elite. La edad muestra una importancia moderada, con un peak de probabilidad entre 30-40 años.


Falsos Negativos (3.75% de los casos): Mayor concentración en regiones mineras. Falsos Positivos (2.23% de los casos): Mayor concentración en RM.

Table 19: Matriz de confusión

Prediction	Reference	Freq
No	No	2911
Si	No	73
No	Si	123
Si	Si	169

Table 20: Métricas de rendimiento del modelo

	Métrica	Valor
Accuracy	Accuracy	0.940
Sensitivity	Sensitivity	0.976
Specificity	Specificity	0.579
	AUC	0.939



Este análisis sugiere que la pertenencia al 10% superior en Chile está fuertemente estructurada por la combinación de educación y territorio, con la edad jugando un rol moderador. Los errores del modelo

iluminan casos donde esta estructura se rompe, sea por rutas alternativas de acceso a altos ingresos (regiones mineras) o por barreras que impiden que el capital educativo se traduzca en retornos económicos equiparables (RM).

Variables de bienestar: Muestran una importancia moderada pero reveladora en el modelo. El logro de metas y el apoyo a la empleabilidad emergen como los predictores más importantes. La interferencia doméstica y el balance trabajo-vida muestran una importancia menor pero significativa. El indicador de missing en variables de bienestar resultó ser en sí mismo predictivo

Patrones Identificados: Mayor bienestar subjetivo se asocia con mayor probabilidad de pertenecer al 10% superior. Los falsos positivos del modelo (personas predichas como elite pero que no lo son) tienden a mostrar niveles de bienestar similares a la elite real. La flexibilidad laboral y el control sobre el tiempo muestran una relación no lineal con la pertenencia al grupo elite.

Las variables de bienestar laboral y uso del tiempo solo aplican a personas ocupadas. No son “no respuestas” sino “no aplica” para personas fuera del mercado laboral. Esto significa que los missing no son aleatorios sino que están estructuralmente relacionados con la situación laboral.

Implicaciones para el Modelo: El indicador bienestar_missing está en realidad capturando principalmente situación ocupacional Su poder predictivo (que resultó significativo) probablemente refleja que la pertenencia al 10% superior está fuertemente asociada a la participación en el mercado laboral.

Table 21: Resumen de errores de clasificación


Tipo de error	Cantidad	Porcentaje
Correcto	3080	94.02
Falso Negativo	123	3.75
Falso Positivo	73	2.23

Table 22: Distribución de errores por región

region	Correcto	Falso Negativo	Falso Positivo
1	164	12	3
10	185	6	6
11	185	7	3
12	154	6	2
13	314	20	26
14	179	2	5
15	149	6	6
16	188	7	3
2	168	17	0
3	188	4	5
4	187	7	2
5	232	7	6
6	192	3	1
7	176	6	2
8	216	7	2
9	203	6	1

Distribución de probabilidades predichas por tipo de error

Análisis de errores de clasificación



Conclusiones generales:

El modelo alcanza una precisión del 94%, sugiriendo que la pertenencia a este grupo está fuertemente determinada por una combinación de educación universitaria/postgrado y ubicación territorial, especialmente en la Región Metropolitana. Las variables de bienestar, aunque significativas, deben interpretarse con cautela pues solo aplican a ocupados. Los errores del modelo identifican un grupo de falsos positivos con características similares a la elite pero sin los ingresos correspondientes concentrados en la RM y falsos negativos, especialmente en regiones mineras (ambos posiblemente explicados por la variable educación). En un ejercicio posterior se podría agregar la variable comuna para el caso de la RM para mayor precisión.

Bibliografía:

- Gilens, M. (2012). *Affluence and influence: Economic inequality and political power in America*. Princeton, NJ: Princeton University Press.
- Hernando, M. & Mitchell, G. (2023). *Uncomfortably off: Why the Top 10% of Earners Should Care about Inequality*. Bristol: Policy Press.
- Mac-Clure, O., Barozet, E., & Maturana, V. (2014). Desigualdad, clase media y territorio en Chile: ¿clase media global o múltiples mesocracias según territorios?. *Revista EURE - Revista De Estudios Urbano Regionales*, 40(121).
- Méndez, M.L., & Gayo, M. (2024). *The Politics of the Elite: Ideological Orientations, Mothering, and Social Mobilities in Neoliberal Chile*. London: Routledge.
- Rothman, K. J., & Greenland, S. (2018). Planning Study Size Based on Precision Rather Than Power. *Epidemiology*, 29(5), 599-603.

- van Smeden, M., Moons, K. G., de Groot, J. A., Collins, G. S., Altman, D. G., Eijkemans, M. J., & Reitsma, J. B. (2019). Sample size for binary logistic prediction models: Beyond events per variable criteria. *Statistical Methods in Medical Research*, 28(8), 2455-2474.
- Wilkinson, R. & Pickett, K. (2010). *The spirit level: Why equality is better for everyone*. London: Penguin.
- Wilkinson, R. & Pickett, K. (2019). *The inner level: How more equal societies reduce stress, restore sanity and improve everyone's well-being*. London: Penguin.